

Árboles de Regresión

Jorge Gallego

Inter-American Development Bank

2026

Introducción

- Vimos la esencia de los árboles de clasificación
- Dividir el conjunto de opciones en diferentes subconjuntos por medio de splits en las características
- La idea es pasar de grupos heterogéneos a conjuntos homogéneos
- Al final, la categoría a la que pertenezcan la mayoría de objetos determina la predicción
- Veremos que este método también sirve para hacer predicción numérica
- Por medio de los *árboles de regresión* y los árboles modelo

Introducción

- Los árboles de regresión fueron introducidos en los 1980's con el algoritmo CART (*Classification and Regression Tree*)
- A pesar del nombre, no se usan métodos de regresión
- Las predicciones se basan en el el promedio de los valores de los objetos que quedan en cada hoja
- Luego en lugar de usar la regla de la mayoría (como en clasificación), promediamos

Introducción

- Los árboles modelo (*model trees*) fueron introducidos después de los árboles de regresión
- Se construyen de la misma forma: haciendo *splits* en las variables de interés
- Pero en cada nodo terminal (hoja), se corre un modelo de regresión múltiple usando las observaciones de ese nodo
- Dependiendo del número de nodos terminales pueden terminar corriéndose muchos modelos
- Al final, son menos intuitivos pero pueden ser más precisos que los árboles de regresión

Ventajas de estos Modelos

Las principales ventajas de estos modelos son:

1. Combinan las fortalezas de los árboles de decisión para modelar *outcomes* numéricos
2. No se requiere especificar un modelo ex ante
3. La selección de características es automática, luego pueden usarse muchas
4. Se alcanza mejor ajuste que con regresiones para ciertos tipos de datos
5. La interpretación de los resultados puede ser intuitiva

Desventajas de estos Modelos

Las principales desventajas son:

1. Menos conocidos que la regresión lineal
2. Se requieren muchos datos de entrenamiento
3. Difícil determinar el efecto neto total de una característica sobre el *outcome*
4. Árboles muy grandes pueden ser más difíciles de interpretar

Árboles vs Regresiones

- Para predicción numérica el método de regresión es mucho más popular
- Pero en algunos casos los árboles de regresión y los modelos de árbol son preferibles
- Por ejemplo, cuando hay muchos predictores. O cuando hay no-linealidades
- Además, con los árboles no es necesario imponer muchos de los supuestos sobre la distribución de los datos

Medida de Pureza

- Vimos que la esencia del método es dividir en características que nos lleven a grupos más homogéneos
- En clasificación usamos como medida de pureza el índice de entropía
- Pero dicha medida solo puede usarse para outcomes binarios
- ¿Qué medida podemos usar ahora que el outcome es continuo?

Medida de Pureza

- Para los árboles de regresión usaremos la Reducción en la Desviación Estándar (SDR):

$$SDR = sd(T) - \sum_i \frac{|T_i|}{|T|} \times sd(T_i)$$

- donde $sd(T)$ es la desviación estándar de los valores en el conjunto T
- T_i es el conjunto de valores i que resulta de la división en una característica
- $|T_i|$ es el cardinal del conjunto T_i , o el número de elementos en el conjunto

Medida de Pureza

- Intuitivamente la fórmula mide el cambio en la desviación estándar de los objetos
- Restando a la desviación del conjunto original, la suma ponderada de las desviaciones de los subconjuntos resultantes
- Como antes, el algoritmo divide en la característica que logra el mayor SDR
- Ya que dicha división es la que garantiza subconjuntos más homogéneos

Ejemplo

Consideremos el siguiente ejemplo:

original data	1	1	1	2	2	3	4	5	5	6	6	7	7	7	7
split on feature A	1	1	1	2	2	3	4	5	5	6	6	7	7	7	7
split on feature B	1	1	1	2	2	3	4	5	5	6	6	7	7	7	7

T_1 T_2

Ejemplo

- La desviación estándar del conjunto original es:
 $sd(T) = 2.404361$
- La desv. est. ponderada para el split A es: $sd(A) = 1.201547$
- Luego, para el split A : $SDR_A = 1.202815$
- La desv. est. ponderada para el split B es: $sd(B) = 1.01161$
- Luego, para el split B : $SDR_B = 1.392751$
- Por tanto, es mejor hacer el split B

Ejemplo

- Se hace esto en cada nodo hasta terminar. Qué hacer en cada nodo terminal depende del método
- Bajo un árbol de regresión, se promedia el outcome para todos los objetos en el nodo
- Esa es la predicción para cualquier objeto nuevo que caiga en ese nodo
- Bajo árboles modelo, se corre una regresión y se predice sobre el nuevo outcome

Ejemplo

- En el ejemplo anterior supongamos que hacemos el split en B y se termina el proceso
- Si un objeto cae en T_1 , bajo árbol de regresión la predicción sería: $mean(T_1) = 2$
- Si cae en T_2 , la predicción sería: $mean(T_2) = 6.25$
- Si se usa un árbol modelo, se correría un regresión en cada nodo terminal
- Y se haría el pronóstico con base en dicha regresión