

Aprendizaje de máquinas y análisis de datos

Bogotá Summer School in Economics — 2026

Profesor: Jorge Gallego | Banco Interamericano de Desarrollo | jagallegod@gmail.com

1. Introducción

Las técnicas de aprendizaje automático (*machine learning*) se han consolidado como herramientas fundamentales para el análisis de datos en la era del *big data*. Su impacto trasciende el sector tecnológico y se aplica en múltiples ámbitos. Desde la evaluación de riesgo crediticio y la detección temprana de enfermedades hasta la predicción del crimen y el análisis de deserción estudiantil, el aprendizaje automático impulsa decisiones basadas en datos con un alto grado de precisión y eficiencia.

En este curso, exploraremos las principales técnicas de aprendizaje supervisado, aplicando modelos predictivos a diversos problemas empíricos. En la segunda parte, abordaremos el aprendizaje no supervisado, analizando métodos para la segmentación de datos, detección de anomalías y reducción de dimensionalidad. Finalmente, en la tercera parte, profundizaremos en el aprendizaje profundo (*deep learning*), explorando arquitecturas avanzadas de redes neuronales y sus aplicaciones en problemas complejos de análisis de datos.

2. Metodología

Este curso de 18 horas será teórico-práctico, con presentaciones magistrales en las que el profesor expondrá los principales conceptos estadísticos y matemáticos subyacentes a estas técnicas, seguidas de talleres prácticos en los que se enseñará a los estudiantes a resolver problemas de política pública concretos. Para tal propósito, en el curso usaremos el lenguaje estadístico R y el entorno RStudio, e introduciremos los conocimientos básicos necesarios para aplicar las técnicas que estudiaremos en el curso. Todos los materiales del curso se encontrarán en un repositorio de GitHub <https://github.com/jagallegod/curso-machine-learning-2026>.

3. Contenido

I. Introducción, KNN y Naive Bayes

- a. Introducción al aprendizaje de máquinas
- b. Clasificación usando vecinos más cercanos (KNN)
- c. Aprendizaje probabilístico: Naive Bayes

II. SVM, árboles de decisión y random forests

- a. Support Vector Machines
- b. Árboles de decisión
- c. Bagging y random forests

III. Regresión, Ridge y Lasso

- a. Regresión lineal y logística
- b. Ridge
- c. Lasso

IV. Desempeño de modelos

- a. Evaluación y mejoramiento del desempeño
- b. Feature extraction, selection y engineering
- c. Importancia de variables
- d. Desbalance de clase
- e. Ensamblaje de modelos y overfitting

V. Aprendizaje no supervisado

- a. Introducción
- b. Clustering
- c. Detección de anomalías
- d. Aprendizaje de representación y embeddings

VI. Aprendizaje profundo (deep learning)

- a. Introducción
- b. Redes neuronales artificiales (ANNs)
- c. Redes neuronales convolucionales (CNNs)
- d. Redes neuronales recurrentes (RNNs)

4. Evaluación

La nota final se compone de tres pruebas:

1. **Quiz (33 %)**. Durante la sesión 5. Examen individual, a la antigua (lápiz y papel, sin ningún recurso), enfocado en evaluar la comprensión de los conceptos principales de los modelos vistos en el curso.
2. **Proyecto / *policy report* (33 %)**. Trabajo para la casa: cada estudiante aplica las herramientas del curso a un problema real de política pública. Debe plantear una pregunta de evaluación/investigación, conseguir una base de datos para responderla, diseñar una estrategia empírica (usando uno o varios de los modelos del curso), implementarla y escribir un reporte de política con los resultados. Aquí sí se puede usar todo: material del curso, datos externos, LLMs, etc.

3. **Sustentación (34 %).** Defensa virtual (videollamada) del proyecto, unos días después de la entrega, para verificar que cada estudiante comprende a fondo el trabajo entregado.

5. Políticas del curso

- Se espera que los estudiantes realicen las lecturas asignadas antes de clase.
- Se espera participación activa durante las clases.

6. Bibliografía

- Abadi, M. et al. (2016). *TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems*. <https://www.tensorflow.org/>
- Boehmke, B. y B. Greenwell (2020). *Hands-On Machine Learning with R*. Chapman & Hall/CRC.
- Chollet, F. y J. J. Allaire (2018). *Deep Learning with R*. Manning Publications.
- Conway, D. y J. Myles (2012). *Machine Learning for Hackers*. O'Reilly Media.
- Hastie, T., R. Tibshirani y J. Friedman (2009). *The Elements of Statistical Learning*. Springer.
- James, G., D. Witten, T. Hastie y R. Tibshirani (2013). *An Introduction to Statistical Learning*. Springer.
- Kuhn, M. y K. Johnson (2013). *Applied Predictive Modeling*. Springer.
- Kuhn, M. y J. Silge (2022). *Tidy Modeling with R*. O'Reilly Media.
- Lantz, B. (2015). *Machine Learning with R*. Packt Publishing.
- Matloff, N. (2011). *The Art of R Programming*. No Starch Press.
- Russell, S. y P. Norvig (2020). *Inteligencia Artificial: Un Enfoque Moderno*. Pearson Educación.
- Siegel, E. (2013). *Predictive Analytics*. John Wiley & Sons.
- Wickham, H. y G. Grolemund (2017). *R for Data Science*. O'Reilly Media.
- Zhang, A., Z. C. Lipton, M. Li y A. J. Smola (2021). *Dive into Deep Learning*. <https://d2l.ai/>
- Zumel, N. y J. Mount (2014). *Practical Data Science with R*. Manning Publications.